

# HW6

PB20111689 蓝俊玮

## 6.4

试讨论线性判别分析与线性核支持向量机在何种条件下等价

线性判别分析能够解决  $n$  分类问题，而线性核 SVM 只能解决二分类问题。

从求解的角度来考虑，线性判别分析的目标是要让同类的投影点尽可能接近，而异类样例的投影点尽可能远离。而考虑 SVM，SVM 求解出来的超平面会使这两类样例尽可能远。当线性判别分析的投影向量和线性核 SVM 的超平面向量垂直的时候，可以看出，SVM 的最大间隔就是线性判别分析所要求的异类投影点间距，同时在这种情况下，线性判别分析的同类样例的投影点也会被这个超平面所划分在一起，使其间隔较小。

所以如果线性判别分析求解出来的投影向量  $w_1$  和线性核 SVM 求解出来的超平面向量  $w_2$  垂直的时候，以及在数据集只有两类的时候和数据集时线性可分的情况下，两种是等价的。

## 6.6

试分析 SVM 对噪声敏感的原因

SVM 的基本形态是一个硬间隔分类器，它要求所有样本都满足硬间隔约束。因此噪声很容易影响 SVM 的学习。同时存在噪声时，SVM 容易受噪声信息的影响，将训练得到的超平面向两个类间靠拢，导致训练的泛化能力降低，尤其是当噪声成为支持向量时，会直接影响整个超平面。并且当 SVM 推广到使用核函数时，会得到一个更复杂的模型，此时噪声也会一并被映射到更高维的特征，可能会对训练造成更意想不到的结果。因此 SVM 对噪声敏感。

## 6.9

试使用核技巧推广对率回归，产生“核对率回归”

原始对率回归问题为

$$\min_{\beta} E = l(\beta) = \sum_{i=1}^m (-y_i \beta^T \mathbf{x}_i + \ln(1 + e^{\beta^T \mathbf{x}_i})) \quad (3.27)$$

则由表示定理，可以写出

$$h(\mathbf{x}) = \sum_{i=1}^m \alpha_i \kappa(\mathbf{x}, \mathbf{x}_i)$$

再有

$$h(\mathbf{x}) = \beta^T \phi(\mathbf{x})$$

得到

$$\beta = \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)$$

则可以得到

$$\begin{aligned} \min_{\alpha} E &= \sum_{i=1}^m (-y_i \sum_{j=1}^m \alpha_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) + \ln(1 + e^{\sum_{j=1}^m \alpha_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)})) \\ \min_{\alpha} E &= \sum_{i=1}^m (-y_i \sum_{j=1}^m \alpha_j \kappa(\mathbf{x}_i, \mathbf{x}_j) + \ln(1 + e^{\sum_{j=1}^m \alpha_j \kappa(\mathbf{x}_i, \mathbf{x}_j)})) \\ \min_{\alpha} E &= \sum_{i=1}^m (-y_i \sum_{j=1}^m \alpha_j K_{ij} + \ln(1 + e^{\sum_{j=1}^m \alpha_j K_{ij}})) \end{aligned}$$

## T4

设原式中的  $\alpha = \tilde{\alpha}$

则设

$$\alpha = \begin{pmatrix} \tilde{\alpha} \\ \hat{\alpha} \end{pmatrix} \quad v = \begin{pmatrix} -y - \varepsilon \\ y - \varepsilon \end{pmatrix}$$

同时

$$\tilde{\alpha}^T K \tilde{\alpha} - \tilde{\alpha}^T K \hat{\alpha} - \hat{\alpha}^T K \tilde{\alpha} + \hat{\alpha}^T K \hat{\alpha} = \alpha^T \begin{pmatrix} \kappa & -\kappa \\ -\kappa & \kappa \end{pmatrix} \alpha$$

则设

$$K = \begin{pmatrix} \kappa & -\kappa \\ -\kappa & \kappa \end{pmatrix}$$

最后设

$$u = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

则根据这些  $\alpha, v, K, u$ , 可以将支持向量回归的对偶问题转化为如下标准形式:

$$\begin{aligned} \max_{\alpha} g(\alpha) &= \alpha^T v - \frac{1}{2} \alpha^T K \alpha \\ s.t. \quad C &\geq \alpha \geq 0 \text{ and } \alpha^T u = 0 \end{aligned}$$

## T5

取平方项默认的映射空间大小:

$$\begin{aligned} \kappa(x_i, x_j) &= \phi(x_i)^T \phi(x_j) = (x_i^T x_j)^2 = (x_{i1}x_{j1} + x_{i2}x_{j2} + \dots + x_{in}x_{jn})^2 = \sum_{k=1}^{k=n} (x_{ik}x_{jk})^2 + 2 \times \sum_{k=1}^{k=n} \sum_{l \neq k} x_{ik}x_{jk}x_{il}x_{jl} \\ \Rightarrow \quad \phi(x_i) &= \left( \frac{\sqrt{2}}{\sqrt{i_1!i_2! \dots i_n!}} x_{i1}^{i_1} x_{i2}^{i_2} \dots x_{in}^{i_n} \right) \quad i_1 + i_2 + \dots + i_n = 2 \end{aligned}$$

即有:

$$\phi(x_i) = (x_{i1}^2, \sqrt{2}x_{i1}x_{i2}, \sqrt{2}x_{i1}x_{i3}, \dots, x_{i2}^2, \dots, x_{in}^2, \dots)$$