

HW10

PB20111689 蓝俊玮

T1

因为有：

$$\sum_c P(c|\mathbf{x})P(c|\mathbf{z}) \leq \max_{c \in \mathcal{Y}} P(c|\mathbf{x}) \sum_c P(c|\mathbf{z}) = \max_{c \in \mathcal{Y}} P(c|\mathbf{x})$$

所以可以得到：

$$err^*(\mathbf{x}) = 1 - \max_{c \in \mathcal{Y}} P(c|\mathbf{x}) \leq 1 - \sum_c P(c|\mathbf{x})P(c|\mathbf{z}) = err(\mathbf{x})$$

记 $err^*(\mathbf{x}) = 1 - P(c^*|\mathbf{x})$ 同时也有：

$$\begin{aligned} err(\mathbf{x}) &= 1 - \sum_c P(c|\mathbf{x})P(c|\mathbf{z}) \\ &\approx 1 - \sum_c P^2(c|\mathbf{x}) \\ &= 1 - P^2(c^*|\mathbf{x}) - \sum_{c \neq c^*} P^2(c|\mathbf{x}) \\ &= (1 + P(c^*|\mathbf{x}))(1 - P(c^*|\mathbf{x})) - \sum_{c \neq c^*} P^2(c|\mathbf{x}) \\ &= (2 - err^*(\mathbf{x}))err^*(\mathbf{x}) - \sum_{c \neq c^*} P^2(c|\mathbf{x}) \end{aligned}$$

由柯西不等式可以得到：

$$\sum_{c \neq c^*} P^2(c|\mathbf{x}) \geq \frac{1}{|\mathcal{Y}| - 1} \left(\sum_{c \neq c^*} P(c|\mathbf{x}) \right)^2 = \frac{1}{|\mathcal{Y}| - 1} (1 - P(c^*|\mathbf{x}))^2 = \frac{1}{|\mathcal{Y}| - 1} (err^*(\mathbf{x}))^2$$

将该式代入前式，可以得到：

$$\begin{aligned} err(\mathbf{x}) &\leq (2 - err^*(\mathbf{x}))err^*(\mathbf{x}) - \frac{1}{|\mathcal{Y}| - 1} (err^*(\mathbf{x}))^2 \\ &= err^*(\mathbf{x}) \left(2 - \frac{|\mathcal{Y}|}{|\mathcal{Y}| - 1} \times err^*(\mathbf{x}) \right) \end{aligned}$$

综上所述，可以知道：

$$err^*(\mathbf{x}) \leq err(\mathbf{x}) \leq err^*(\mathbf{x}) \left(2 - \frac{|\mathcal{Y}|}{|\mathcal{Y}| - 1} \times err^*(\mathbf{x}) \right)$$

T2

在实践中，协方差矩阵 $\mathbf{X}\mathbf{X}^T$ 的特征值分解常由中心化后的样本矩阵 \mathbf{X} 的奇异值分解代替，试述其原因

\mathbf{X} 有奇异值分解为 $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ ，则 $\mathbf{X}\mathbf{X}^T = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{V}\mathbf{\Sigma}^T\mathbf{U}^T$ ，而 $\mathbf{V}^T\mathbf{V} = \mathbf{I}$ ，因此有 $\mathbf{X}\mathbf{X}^T = \mathbf{U}\mathbf{\Sigma}\mathbf{\Sigma}^T\mathbf{U}^T = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^T$ 。

而对 $\mathbf{X}\mathbf{X}^T$ 特征值分解有 $\mathbf{X}\mathbf{X}^T = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^T$ 。只要让 $\mathbf{P} = \mathbf{U}$ ，所以可以用奇异值分解来代替特征值分解，可以节省计算和存储的成本，且计算精度较高。

T3

$$L(\mathbf{W}) = \text{tr}(\mathbf{W}^T \mathbf{X}\mathbf{X}^T \mathbf{W}) - \text{tr}(\mathbf{\Lambda}^T (\mathbf{W}^T \mathbf{W} - \mathbf{I}_{d'}))$$

$$\frac{\partial L(\mathbf{W})}{\partial \mathbf{W}} = (\mathbf{X}\mathbf{X}^T + \mathbf{X}\mathbf{X}^T) \mathbf{W} - (\mathbf{W}\mathbf{\Lambda} + \mathbf{W}\mathbf{\Lambda}^T) = 2\mathbf{X}\mathbf{X}^T \mathbf{W} - 2\mathbf{W}\mathbf{\Lambda}$$

令 $\frac{\partial L(\mathbf{W})}{\partial \mathbf{W}} = 0$ ，可以求得：

$$\mathbf{X}\mathbf{X}^T \mathbf{W} = \mathbf{W}\mathbf{\Lambda}$$

将 \mathbf{W} 和 $\mathbf{\Lambda}$ 展开（对协方差矩阵 $\mathbf{X}\mathbf{X}^T$ 进行特征值分解并将特征值进行排序），可以得到：

$$\mathbf{X}\mathbf{X}^T \mathbf{w}_i = \lambda_i \mathbf{w}_i \quad i = 1, 2, \dots, d'$$

将特征向量构成 $\mathbf{W} = (\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'})$ 就是主成分分析的解。

T4

不是凸优化问题。因为 P 不能满足是凸集。

同时

$$f(P) = \sum_{(x_i, x_j) \in \mathcal{M}} (x_i - x_j)^T P P^T (x_i - x_j)$$

$$g(P) = 1 - \sum_{(x_i, x_j) \in \mathcal{M}} (x_i - x_j)^T P P^T (x_i - x_j)$$

则对于原问题就有：

$$\min_P f(P) \quad s.t. \quad g(P) \leq 0$$

可知 $f(P)$ 和 $g(P)$ 的二阶导数符号是相反的，因此 $f(P)$ 和 $g(P)$ 不能同时为凸函数，因此不是凸优化问题。